

UNIVERSIDADE DE COIMBRA

Faculdade de Ciências e Tecnologia da Universidade de Coimbra



Classificação de Atividades Humanas

Meta 1

Trabalho realizado no âmbito da edição de 2025/2026 da disciplina de Engenharia de Características para Aprendizagem Computacional da responsabilidade do docente Marco António Machado Simões do Departamento de Engenharia Informática da Licenciatura em Engenharia Informática da Faculdade de Ciências e Tecnologias da Universidade de Coimbra.

José Amado, Guilherme Carvalho

Coimbra, 2025

Índice

- 1. Introdução**
- 2. Dados e Contexto**
- 3. Cálculo dos Módulos dos Vetores**
- 4. Detecção de Outliers**
- 5. Segmentação Temporal e Extração de Features**
- 6. Normalização e PCA**
- 7. Seleção de Features: Fisher Score e Relief**

1. Introdução

O reconhecimento de atividades humanas é relevante em áreas como monitorização clínica, desporto, reabilitação e interação humano-máquina. A eficácia da classificação depende fortemente das etapas de pré-processamento e engenharia de características. Assim, o foco desta meta é a preparação dos dados e a análise aprofundada da estrutura dos sinais, antes da fase de classificação.

2. Dados e Contexto

Os dados pertencem ao dataset, recolhido com 5 sensores colocados em: pulso esquerdo, pulso direito, peito, perna superior direita, perna inferior esquerda. Foram observados 15 participantes que realizaram 16 atividades (ex.: *Stand*, *Sit*, *Walk*, *Climb Stairs*, *Sit→Stand*, *Walk→Stand*, etc.).

Cada sensor regista: aceleração (x, y, z), velocidade angular (x, y, z), campo magnético (x, y, z), timestamp e label da atividade (1–16). Para análise independente da orientação, utilizou-se o módulo:

$$|v| = \sqrt{x^2 + y^2 + z^2}$$

Os dados foram carregados e concatenados num único array numpy.

partX/partXdevY.csv

3. Cálculo dos Módulos

Esta transformação elimina a dependência da orientação do sensor e preserva a magnitude do movimento. É particularmente útil neste projeto porque os sensores podem sofrer rotações pequenas durante as atividades, e o objetivo é captar apenas a intensidade global do movimento, não a sua direção. Após o cálculo dos módulos $|Acc|$, $|Gyro|$ e $|Mag|$, os sinais foram inspecionados graficamente e analisados.

4. Detecção de Outliers

A deteção de outliers é essencial para eliminar ruído e picos anómalos que podem distorcer médias ou variâncias. Foram aplicadas quatro abordagens complementares:

- IQR: Baseia-se nos quartis Q1 e Q3 considerando um ponto é outlier se estiver fora de $[Q1 - 1.5 \times IQR, Q3 + 1.5 \times IQR]$ sendo ideal para distribuições assimétricas.
- Z-Score ($k=3$): Mede o número de desvios-padrão em relação à média sendo adequado para distribuições aproximadamente normais. Produziu densidades de outliers de apenas 0.8%–2.6%, revelando um método conservador.
- K-Means Clustering: Identificou padrões de comportamento distintos. Representa dois regimes distintos: movimentos suaves vs intensos.
- DBSCAN: Modelo de densidade que detetou 42 clusters e classificou 842 pontos como ruído. Mostrou-se sensível ao parâmetro de densidade ϵ , mas eficaz na detecção de padrões não lineares.




Gráfico com boxplots de módulos da aceleração para cada atividade
para o dispositivo 1




Gráfico com boxplots de módulos da velocidade angular para cada atividade para o dispositivo 1




Gráfico com boxplots de módulos do campo magnético para cada atividade para o dispositivo 1


Activity	Acceleration Outlier Density (%)	Magnetic Field Outlier Density (%)	Angular Velocity Outlier Density (%)
1	4,81	0	9,56
2	0,24	7,19	6,66
3	1,32	0	9,1
4	3,5	1,3	1,76
5	3,36	1,28	1,48
6	5,1	0,41	1,54
7	4,38	0,25	2,1
8	15,53	3,39	7,31
9	20,08	7,7	9,14
10	17,53	0,13	10,37
11	18,25	7,23	11,32
12	10,69	0,03	3,49
13	5,37	0	8,49
14	12,85	5,82	2,56
15	4,95	7,14	3,04
16	4,84	1,29	2,02

Densidade de Outliers para cada atividade calculada via IQR

Activity	Acceleration Outlier Density (%)	Magnetic Field Outlier Density (%)	Angular Velocity Outlier Density (%)
1	0,86	0	1,53
2	0,26	0	0,49
3	0,39	0	0,67
4	1,1	0,08	0,94
5	1,07	0,07	0,87
6	1,23	0,52	0,91
7	1,26	0,4	1,08
8	1,82	2,26	1,82
9	2,62	0,02	2,21
10	2,23	0,18	2,2
11	2,98	0,02	2,42
12	1,86	0,03	1,6
13	1,31	0	2,53
14	1,29	0	1,57
15	1,24	0	0,9
16	1,35	0,06	1,07


Densidade de Outliers para cada atividade calculada via Z-Score

KMeans clusters with outliers - Activity 12 - Device 1



Outliers detectados pelo K-Means Clustering na atividade 12 e dispositivo 1
(a atividade 12 é a transição de estar parado para andar)

DBSCAN Clusters - Activity 12 - Device 1



Outliers detectados pelo DBSCAN Clustering na atividade 12 e dispositivo 1
(a atividade 12 é a transição de estar parado para andar)

5. Extração de Features

Os dados contínuos foram divididos em janelas de 5 segundos, com 50% de overlap presumidamente para criar um equilíbrio entre resolução temporal e estabilidade estatística. Para cada janela, foram calculadas as seguintes features: Mean value, Standard deviation, Median value, Variance, RMS, Averaged Deviation, Skewness, Kurtosis, IQR, ZRC, MCR e Spectral Entropy. Estas features captam tanto a intensidade média como a dinâmica oscilatória do movimento.

6. Normalização e PCA

A normalização via z-score assegura que cada feature contribui igualmente, eliminando efeitos de escala. O PCA (Principal Component Analysis) foi aplicado à matriz de features normalizadas para identificar direções de maior variância. Os resultados mostraram:

- 1ª componente → 47%
- 2ª componente → 14%
- 3ª componente → 11%
- 4ª componente → 8%
- Cumulativo → 77% da variância explicada

Assim, apenas 4 componentes são suficientes para representar a maioria da variabilidade original, reduzindo redundância e ruído.




Gráfico da análise do PCA

7. Seleção de Features

A seleção de features visou identificar as variáveis mais discriminantes entre atividades. Foram usados dois métodos:

- Fisher Score: quantifica a razão entre variabilidade entre classes e dentro da classe.
- Relief: analisa diferenças locais entre vizinhos próximos de classes distintas.

Feature	Score
acc_mean_crossing_rate	5,7121
mag_mean_crossing_rate	3,4325
gyro_mean	3,402
gyro_rms	3,2324
gyro_median	3,0094
acc_iqr	2,229
gyro_std	2,2085
gyro_average_deviation	2,1106
acc_average_deviation	1,9094
acc_std	1,8184

Top 10 features via Fisher Score

Feature	Score
gyro_mean	0,8663
acc_mean_crossing_rate	0,8547
gyro_median	0,8532
gyro_rms	0,8472
acc_iqr	0,7759
gyro_std	0,753
mag_mean_crossing_rate	0,7528
gyro_average_deviation	0,7513
acc_average_deviation	0,739
gyro_iqr	0,7292

Top 10 features via Relief