

UNIVERSIDADE DE COIMBRA

Faculdade de Ciências e Tecnologia da Universidade de Coimbra



Classificação de Atividades Humanas

Trabalho realizado no âmbito da edição de 2025/2026 da disciplina de Engenharia de Características para Aprendizagem Computacional da responsabilidade do docente Marco António Machado Simões do Departamento de Engenharia Informática da Licenciatura em Engenharia Informática da Faculdade de Ciências e Tecnologias da Universidade de Coimbra.

José Amado, Guilherme Carvalho

Coimbra, 2025

Índice

- 1. Introdução (3)**
- 2. Dados e Contexto (3)**
- 3. Cálculo dos Módulos dos Vetores (3)**
- 4. Detecção de Outliers (4)**
- 5. Testes de Normalidade (8)**
- 6. Extração de Features (9)**
- 7. Normalização e PCA (9)**
- 8. Seleção de Features (10)**
- 9. Aumentação dos Dados (11)**
- 10. Embeddings (12)**
- 11. Estratégias de Divisão de Dados (12)**
- 12. Classificador k-Nearest Neighbors (13)**
- 13. Avaliação dos Modelos (14)**
- 14. Testes de Hipótese (16)**
- 15. Modelo de Implantação (18)**

1. Introdução

O reconhecimento de atividades humanas é relevante em áreas como monitorização clínica, desporto, reabilitação e interação humano-máquina. A eficácia da classificação depende fortemente das etapas de pré-processamento e engenharia de características. Assim, o foco desta meta é a preparação dos dados e a análise aprofundada da estrutura dos sinais, antes da fase de classificação.

2. Dados e Contexto

Os dados pertencem ao dataset, recolhido com 5 sensores colocados em: pulso esquerdo, pulso direito, peito, perna superior direita, perna inferior esquerda. Foram observados 15 participantes que realizaram 16 atividades (ex.: *Stand*, *Sit*, *Walk*, *Climb Stairs*, *Sit→Stand*, *Walk→Stand*, etc.).

Cada sensor regista: aceleração (x, y, z), velocidade angular (x, y, z), campo magnético (x, y, z), timestamp e label da atividade (1–16). Para análise independente da orientação, utilizou-se o módulo:

$$|v| = \sqrt{x^2 + y^2 + z^2}$$

Os dados foram carregados e concatenados num único array numpy.

3. Cálculo dos Módulos

Esta transformação elimina a dependência da orientação do sensor e preserva a magnitude do movimento. É particularmente útil neste projeto porque os sensores podem sofrer rotações pequenas durante as atividades, e o objetivo é captar apenas a intensidade global do movimento, não a sua direção. Após o cálculo dos módulos $|Acc|$, $|Gyro|$ e $|Mag|$, os sinais foram inspecionados graficamente e analisados.

4. Detecção de Outliers

A detecção de outliers é essencial para eliminar ruído e picos anómalos que podem distorcer médias ou variâncias. Foram aplicadas quatro abordagens complementares:

- IQR: Baseia-se nos quartis Q1 e Q3 considerando um ponto é outlier se estiver fora de $[Q1 - 1.5 \times IQR, Q3 + 1.5 \times IQR]$ sendo ideal para distribuições assimétricas.
- Z-Score ($k=3$): Mede o número de desvios-padrão em relação à média sendo adequado para distribuições aproximadamente normais. Produziu densidades de outliers de apenas 0.8%–2.6%, revelando um método conservador.
- K-Means Clustering: Identificou padrões de comportamento distintos. Representa dois regimes distintos: movimentos suaves vs intensos.
- DBSCAN: Modelo de densidade que detetou 42 clusters e classificou 842 pontos como ruído. Mostrou-se sensível ao parâmetro de densidade ϵ , mas eficaz na detecção de padrões não lineares.

O método IQR, representado através dos boxplots, permitiu observar a dispersão dos dados e identificar outliers de forma robusta. Mostrou distribuições concentradas em atividades estáticas e maior variabilidade nas dinâmicas e de transição. O método do Z-score mostrou-se mais sensível a valores extremos e distribuições assimétricas. Em comparação, o IQR produz resultados mais consistentes e estáveis, enquanto o Z-score destaca melhor os picos anómalos. O IQR é mais adequado para caracterizar a variabilidade geral revelando-se mais adequado devido à não normalidade dos dados, enquanto o Z-score será melhor para identificar eventos raros e intensos.




Gráfico com boxplots de módulos da aceleração para cada atividade
para o dispositivo 1




Gráfico com boxplots de módulos da velocidade angular para cada atividade
para o dispositivo 1




Gráfico com boxplots de módulos do campo magnético para cada atividade
para o dispositivo 1


Activity	Acceleration Outlier Density (%)	Magnetic Field Outlier Density (%)	Angular Velocity Outlier Density (%)
1	4,81	0	9,56
2	0,24	7,19	6,66
3	1,32	0	9,1
4	3,5	1,3	1,76
5	3,36	1,28	1,48
6	5,1	0,41	1,54
7	4,38	0,25	2,1
8	15,53	3,39	7,31
9	20,08	7,7	9,14
10	17,53	0,13	10,37
11	18,25	7,23	11,32
12	10,69	0,03	3,49
13	5,37	0	8,49
14	12,85	5,82	2,56
15	4,95	7,14	3,04
16	4,84	1,29	2,02

Densidade de Outliers para cada atividade calculada via IQR

Activity	Acceleration Outlier Density (%)	Magnetic Field Outlier Density (%)	Angular Velocity Outlier Density (%)
1	0,86	0	1,53
2	0,26	0	0,49
3	0,39	0	0,67
4	1,1	0,08	0,94
5	1,07	0,07	0,87
6	1,23	0,52	0,91
7	1,26	0,4	1,08
8	1,82	2,26	1,82
9	2,62	0,02	2,21
10	2,23	0,18	2,2
11	2,98	0,02	2,42
12	1,86	0,03	1,6
13	1,31	0	2,53
14	1,29	0	1,57
15	1,24	0	0,9
16	1,35	0,06	1,07


Densidade de Outliers para cada atividade calculada via Z-Score

KMeans clusters with outliers - Activity 12 - Device 1



Outliers detectados pelo K-Means Clustering na atividade 12 e dispositivo 1
(a atividade 12 é a transição de estar parado para andar)

DBSCAN Clusters - Activity 12 - Device 1



Outliers detectados pelo DBSCAN Clustering na atividade 12 e dispositivo 1
(a atividade 12 é a transição de estar parado para andar)

5. Testes de Normalidade

Os resultados obtidos mostram que as três variáveis analisadas: Aceleração, Velocidade Angular e Campo Magnético não seguem uma distribuição normal em nenhuma das 16 atividades avaliadas, com p-valores menores que 0,05 em todos os casos. Dada esta não normalidade, foi aplicado o teste não paramétrico de Kruskal-Wallis para comparar os valores médios entre atividades, revelando diferenças estatisticamente significativas em todas as variáveis, indicando que estas possuem capacidade discriminante entre atividades. A variável |Gyro| apresenta a maior variação média, sugerindo ser a mais informativa para distinguir atividades, enquanto |Acc| e |Mag|, apesar de variarem menos, também contribuem para a separação entre grupos. Estes resultados confirmam que a extração de características médias a partir dos sensores é relevante para compressão do espaço do problema e para a implementação de soluções de classificação.

Activity	Mean	p-value	Normality
1	9,8806	0	Not normal
2	9,9307	0	Not normal
3	9,9254	0	Not normal
4	10,4476	0	Not normal
5	10,4177	0	Not normal
6	10,4439	0	Not normal
7	10,4064	0	Not normal
8	9,9362	0	Not normal
9	9,8967	0	Not normal
10	9,933	0	Not normal
11	9,8959	0	Not normal
12	10,1823	0	Not normal
13	9,884	0	Not normal
14	10,2931	0	Not normal
15	10,4977	0	Not normal
16	10,5499	0	Not normal

Aceleração

Activity	Mean	p-value	Normality
1	2,8775	0	Not normal
2	1,3976	0	Not normal
3	1,8301	0	Not normal
4	81,8817	0	Not normal
5	81,3966	0	Not normal
6	93,0906	0	Not normal
7	92,2318	0	Not normal
8	17,232	0	Not normal
9	16,9452	0	Not normal
10	15,3784	0	Not normal
11	16,5556	0	Not normal
12	50,6187	0	Not normal
13	4,8784	0	Not normal
14	61,7761	0	Not normal
15	84,7289	0	Not normal
16	88,7931	0	Not normal

Velocidade Angular

Activity	Mean	p-value	Normality
1	1,1186	0	Not normal
2	1,289	0	Not normal
3	1,2738	0	Not normal
4	1,0816	0	Not normal
5	1,0793	0	Not normal
6	1,2549	0	Not normal
7	1,2521	0	Not normal
8	1,2849	0	Not normal
9	1,247	0	Not normal
10	1,2761	0	Not normal
11	1,2408	0	Not normal
12	1,1478	0	Not normal
13	1,0605	0	Not normal
14	1,1563	0	Not normal
15	1,0272	0	Not normal
16	1,0398	0	Not normal

Campo Magnético

6. Extração de Features

Os dados contínuos foram divididos em janelas de 5 segundos, com 50% de overlap presumidamente para criar um equilíbrio entre resolução temporal e estabilidade estatística. Para cada janela, variável e eixo, foram calculadas as seguintes features: Mean value, Standard deviation, Median value, Variance, RMS, Averaged Deviation, Skewness, Kurtosis, IQR, ZRC, MCR e Spectral Entropy. Estas features captam tanto a intensidade média como a dinâmica oscilatória do movimento.

7. Normalização e PCA

A normalização via z-score assegura que cada feature contribui igualmente, eliminando efeitos de escala. O PCA reduz a dimensionalidade, elimina redundâncias e acelera o processamento, mas perde interpretabilidade física e não garante a melhor separação entre classes, pois é um método não supervisionado. Foi aplicado à matriz de features normalizadas para identificar direções de maior variância. Os resultados mostraram:

- Cumulativo de 17 componentes → 77% da variância explicada

Assim, 17 componentes são suficientes para representar a maioria da variabilidade original, reduzindo redundância e ruído.




Gráfico da análise do PCA

As features comprimidas obtêm-se projetando os dados normalizados no espaço das quatro primeiras componentes principais. Para um instante concreto, o vetor original (com dezenas de variáveis) transforma-se num vetor de quatro dimensões que sintetiza a variabilidade principal do sinal.

8. Seleção de Features

A seleção de features visou identificar as variáveis mais discriminantes entre atividades. Foram usados dois métodos:

- Fisher Score: quantifica a razão entre variabilidade entre classes e dentro da classe.
- Relief: analisa diferenças locais entre vizinhos próximos de classes distintas.

Rank	Feature	Score
1	Gyroscope Y RMS	3,646
2	Acceleration Y Std	3,3543
3	Gyroscope Y Std	3,223
4	Acceleration Y Average Deviation	3,0973
5	Gyroscope Y Average Deviation	2,8366
6	Magnetometer X Mean Crossing Rate	2,2311
7	Magnetometer X Std	2,0611
8	Gyroscope Y IQR	1,8521
9	Magnetometer Z Mean Crossing Rate	1,8176
10	Acceleration Y IQR	1,7983

Top 10 features via Fisher Score

Rank	Feature	Score
1	Gyroscope Z Spectral Entropy	0,089
2	Magnetometer Z RMS	0,0709
3	Gyroscope X Kurtosis	0,0687
4	Acceleration Y Mean Crossing Rate	0,06
5	Magnetometer Y RMS	0,0581
6	Gyroscope Z Mean Crossing Rate	0,0578
7	Gyroscope Z Zero Crossing Rate	0,0554
8	Acceleration Y Variance	0,0472
9	Acceleration Y Spectral Entropy	0,0445
10	Acceleration Y Zero Crossing Rate	0,0409


Top 10 features via Relief

9. Aumentação dos Dados

A distribuição equilibrada das amostras é essencial para garantir que o modelo não se torne enviesado para as classes mais representadas, prejudicando a capacidade de generalização e conduzindo a classificações tendenciosas. Assim procedeu-se à análise do número de segmentos disponíveis para cada atividade:

- Stand: 6629 samples
- Sit: 2783 samples
- Sit and Talk: 2756 samples
- Walk: 5405 samples
- Walk and Talk: 5384 samples
- Climb Stair: 3551 samples
- Climb Stair and Talk: 1819 samples

A avaliação do balanceamento evidencia que o dataset não é uniformemente distribuído. Para corrigir o desequilíbrio identificado durante algumas das seguintes etapas, foi utilizado o método SMOTE que baseia-se na interpolação de amostras existentes da classe minoritária para gerar novos exemplos sintéticos de forma realista. No contexto deste projeto, a técnica foi aplicada diretamente sobre o espaço de dados extraídos das janelas temporais.



Samples Sintéticos

10. Embeddings

Esta consistiu na utilização de um método alternativo de representação das janelas temporais: os embeddings aprendidos através de um modelo de deep learning pré-treinado, Harnet5. Enquanto o conjunto de features desenvolvido anteriormente resulta de medidas estatísticas e espectrais explicitamente definidas, os embeddings são vetores numéricos extraídos de uma rede neuronal treinada noutro dataset e que captam automaticamente padrões complexos do sinal.

11. Estratégias de Divisão de Dados

A estratégia de divisão dos dados é fundamental para garantir uma avaliação rigorosa do desempenho do modelo de classificação. Foram consideradas duas abordagens distintas, seguindo o enunciado:

- Divisão intra-participante (mixed): Cada participante contribui simultaneamente para os conjuntos de treino, validação e teste.
- Divisão inter-participante (participant): Diferentes participantes são atribuídos exclusivamente a cada conjunto.

Ambas as estratégias foram aplicadas a ambos datasets, permitindo o seu emparelhamento e uma comparação direta entre representações distintas dos mesmos segmentos temporais.

Na divisão intra-participante, os dados de cada participante foram divididos segundo uma proporção 60%–20%–20% para treino, validação e teste, respetivamente. Esta estratégia permite assegurar maior homogeneidade entre os conjuntos, reduzindo variabilidade interindividual. No entanto, também apresenta limitações importantes, como por exemplo a produção de resultados demasiado otimistas devido aos padrões específicos de movimento variarem entre indivíduos, podendo o modelo aprender traços idiossincráticos e não generalizáveis.

Na divisão inter-participante, os participantes foram divididos em três grupos exclusivos: 9 participantes para treino, 3 participantes para validação, 3 participantes para teste assegurando que cada conjunto contém apenas dados

de indivíduos distintos. Esta estratégia é metodologicamente mais exigente, mas mais alinhada com a utilização real do sistema de reconhecimento de atividades, uma vez que o modelo é testado em pessoas cujos padrões de movimento não foram observados durante o treino.

A comparação entre as estratégias revela diferenças estruturais na forma como o modelo é validado. A divisão intra-participante tende a produzir métricas mais elevadas, uma vez que as características motoras específicas de cada indivíduo são parcialmente aprendidas e repetidas no conjunto de teste. Já a divisão inter-participante fornece uma avaliação mais conservadora, mas metodologicamente superior, ao avaliar a capacidade do modelo reconhecer atividades de participantes totalmente novos. Em problemas de classificação de atividade humana, onde existe elevada variabilidade biomecânica entre indivíduos, a abordagem inter-participante é, portanto, a que mais fielmente estima o desempenho real do sistema quando aplicado em novos utilizadores.

12. Classificador k-Nearest Neighbors

Nesta etapa, procedeu-se ao desenvolvimento do modelo de aprendizagem automática responsável por classificar cada segmento temporal numa das atividades consideradas. O kNN é particularmente adequado para este tipo de problema, uma vez que não assume uma forma específica para a distribuição das classes e funciona diretamente sobre representações numéricas multidimensionais. A sua performance depende fortemente da escolha da métrica de distância, do valor de k e da qualidade das representações (features ou embeddings).

Para avaliar o desempenho do modelo, foram analisadas as seguintes métricas de classificação:

- Matriz de confusão: Permite analisar erros específicos entre classes.
- Acurácia: Útil para comparação entre modelos.
- Precisão, Recall e F1-score: Calculados com média ponderada.

Após a definição das métricas e dos critérios de avaliação, avançou-se para a comparação sistemática dos 12 modelos resultantes da combinação entre:

- Duas estratégias de divisão do dataset (mixed e participant-based).

- Dois tipos de dados (Features, Embeddings)
- Três cenários (Completa, PCA, ReliefF)

Para cada um dos 12 modelos, testaram-se múltiplos valores de k , avaliando o F1-score de validação em cada caso. O valor de k que maximizou este desempenho foi então adotado para a fase final. Concluída esta etapa, cada modelo foi novamente treinado com train + validation e avaliado no conjunto de teste.

13. Avaliação dos Modelos

Observando as matrizes de confusão, nota-se que há uma confusão significativa entre pares de atividades muito semelhantes, sobretudo aquelas que diferem apenas pela presença da fala. Por exemplo, as classes 2 e 3 apresentam elevada taxa de erro cruzado, indicando que o modelo frequentemente confunde “Sit” com “Sit and Talk”. Um padrão semelhante é observado entre as classes 4 e 5, onde “Walk” e “Walk and Talk” também são erroneamente classificadas. Este comportamento sugere que os sinais capturados pelo modelo não são suficientemente discriminativos para distinguir atividades que diferem apenas por falar, possivelmente porque o fator de fala introduz variações sutis no padrão de movimento que se sobrepõem aos sinais da atividade principal.

Model	Act1 %	Act2 %	Act3 %	Act4 %	Act5 %	Act6 %	Act7 %
Mixed-Features-A	97,22	97,84	98,02	71,82	72,44	72,77	55,72
Mixed-Embeddings-A	90,44	79,62	76,65	55,51	56	51,56	43,6
Mixed-Features-B	98,33	88,97	94,46	65,14	68,53	68,83	52,25
Mixed-Embeddings-B	88,07	72,3	73,15	39,8	42,69	44,36	38,12
Mixed-Features-C	84,53	47,65	45,4	35,49	37,6	38,69	35,35
Mixed-Embeddings-C	86,03	64,14	64,74	59,14	32	42,52	53,42
Participant-Features-A	86,03	84,74	82,44	53,12	49,32	42,52	40,08
Participant-Embeddings-A	79,38	61	44,74	43,55	33,55	40,92	49,82
Participant-Features-B	81,7	56,49	64,49	56,66	33,43	39,31	51,03
Participant-Embeddings-B	78,21	56,42	42,31	34,87	33,91	36,52	40,46
Participant-Features-C	79,15	57,5	54,75	38,43	37,97	48,66	40,46
Participant-Embeddings-C	69,96	14,57	21,99	28,62	29,46	39,41	33,93

Acurácia de modelo para cada atividade

	Pred1	Pred2	Pred3	Pred4	Pred5	Pred6	Pred7
True1	1170	22	102	54	61	0	0
True2	21	308	287	1	0	0	0
True3	80	130	350	3	0	0	0
True4	28	3	11	643	435	18	18
True5	45	0	2	513	578	13	14
True6	0	0	0	10	18	393	364
True7	0	0	0	14	13	171	203

	Pred1	Pred2	Pred3	Pred4	Pred5	Pred6	Pred7
True1	1153	35	140	42	39	0	0
True2	11	318	286	2	0	0	0
True3	63	132	367	1	0	0	0
True4	32	2	16	657	408	21	20
True5	41	1	3	513	567	17	23
True6	0	0	0	14	14	361	396
True7	0	0	0	9	13	157	222

Exemplos de Matriz de Confusão

Fica também claro que os modelos baseados em features superaram consistentemente os baseados em embeddings em todos os cenários. Esse padrão repete-se em todas as variações dos datasets intra-participante e inter-participante. Estes resultados indicam que as features extraídas manualmente fornecem sinais mais discriminativos para a classificação das atividades do que embeddings. Os embeddings parecem perder informações importantes para distinguir entre atividades, sobretudo quando há variações sutis entre classes. O efeito da seleção de features, observa-se que o cenário A de cada dataset apresentou consistentemente o melhor desempenho, enquanto as versões B e C, que representam variações com menos features, registraram quedas nas métricas. Este padrão sugere que a seleção de features não melhorou o desempenho, pelo contrário, a redução ou modificação de features parece ter eliminado informações importantes para a discriminação entre atividades. Nos datasets baseados em embeddings, a diferença entre A, B e C é ainda mais marcada, embora todos apresentem resultados inferiores aos datasets de features.


Model	Acc Mean	Acc Std	Prec Mean	Prec Std	Recall Mean	Recall Std	F1 Mean	F1 Std	Mode k
Mixed-Features-A	0,8209	0,0054	0,8216	0,006	0,8209	0,0054	0,821	0,0056	1
Mixed-Embeddings-A	0,6669	0,007	0,6753	0,0063	0,6696	0,007	0,6709	0,007	1
Mixed-Features-B	0,7691	0,0053	0,7706	0,0052	0,7691	0,0053	0,7694	0,0052	1
Mixed-Embeddings-B	0,5855	0,0053	0,5953	0,0061	0,5855	0,0053	0,5864	0,0052	9
Mixed-Features-C	0,752	0,002	0,7534	0,0189	0,752	0,002	0,7524	0,0197	1
Mixed-Embeddings-C	0,497	0,0032	0,5766	0,0322	0,497	0,0322	0,5157	0,0235	5
Participant-Features-A	0,6084	0,0246	0,6266	0,0247	0,6084	0,0246	0,6089	0,0245	19
Participant-Embeddings-A	0,4764	0,0204	0,488	0,0182	0,4764	0,0204	0,4755	0,0172	19
Participant-Features-B	0,5871	0,0274	0,6066	0,0242	0,5871	0,0274	0,5885	0,0253	17
Participant-Embeddings-B	0,432	0,0211	0,45	0,0245	0,432	0,0211	0,4382	0,0204	19
Participant-Features-C	0,546	0,02	0,5602	0,0217	0,546	0,02	0,548	0,0195	19
Participant-Embeddings-C	0,3795	0,0373	0,4146	0,035	0,3795	0,0373	0,3812	0,0299	11

Tabela de Métricas


14. Testes de Hipótese

A validação final do desempenho baseou-se numa análise estatística para assegurar que as superioridades observadas entre as configurações de modelos possuíam significância real. O processo iniciou-se com a aplicação do teste de Kolmogorov-Smirnov para verificar a aderência das distribuições à normalidade. Os resultados deste teste indicaram que os erros dos modelos seguiam uma distribuição normal, o que permitiu a utilização de testes paramétricos, como o teste t, conferindo maior robustez e sensibilidade às conclusões obtidas.

Através de testes t emparelhados, confirmou-se de forma inequívoca que o uso de features é estatisticamente superior ao uso de embeddings em todos os cenários testados. Da mesma forma, a comparação entre os métodos de seleção revelou que a utilização do conjunto completo de características apresenta um ganho de performance estatisticamente relevante face às abordagens de redução de dimensionalidade por PCA ou seleção por Relief, sugerindo que estas últimas descartam componentes essenciais para a distinção de atividades.




Comparações entre modelos intra-participante



Comparações entre modelos inter-participante

Finalmente, a aplicação de testes t independentes para comparar as estratégias de divisão de dados confirmou que a diferença de desempenho entre a abordagem intra-participante e a inter-participante não é fruto do acaso. Esta evidência estatística valida a hipótese de que modelos avaliados em novos utilizadores sofrem um impacto real na precisão devido à variabilidade biomecânica, consolidando a estratégia baseada em participantes como o método mais honesto e robusto para estimar o sucesso do sistema em cenários reais.



Comparações entre diferentes métodos de partição

15. Modelo de Implantação

Para a fase de deployment, foi selecionado o modelo **Participant-Features-A**, com $k = 19$. Este modelo destaca-se por utilizar o conjunto completo de features, o que provou estatisticamente ser mais eficaz do que o uso de embeddings ou técnicas de redução de dimensionalidade.

A função de classificação segue uma estrutura pipeline que transforma uma janela temporal bruta de 256 amostras (5 segundos a 51.5Hz) numa previsão de atividade seguindo as etapas:

- **Extração de Features:** Cálculo das métricas estatísticas e espectrais para cada eixo de cada variável.
- **Normalização (Z-Score):** Aplicação dos parâmetros de média e desvio padrão guardados durante o treino para alinhar a escala das features.
- **Classificação kNN:** O vetor de features resultante é classificado pelo modelo no espaço multidimensional.

16. Melhorias Abordadas

Para elevar a eficácia do sistema de reconhecimento de atividades, foram identificadas e exploradas diversas vias de otimização, focadas tanto na qualidade dos dados como na parametrização do algoritmo de aprendizagem:

- **Refinação do Dataset:** Procedeu-se à remoção seletiva de outliers identificados pelos métodos IQR e Z-Score, eliminando ruído que poderia distorcer as fronteiras de decisão do kNN.
- **Balanceamento Estratégico:** Utilizou-se a técnica SMOTE no dataset de treino para equilibrar as classes minoritárias prevenindo o enviesamento do modelo para as atividades mais frequentes.
- **Distance Weights:** Atribuição de pesos inversamente proporcionais à distância, garantindo que vizinhos mais próximos tenham maior influência na decisão.

- **Métrica de Manhattan:** Testou-se a distância como alternativa à Euclidiana, por ser frequentemente mais robusta em espaços de características de escalas heterogêneas.
- **Arquitetura Multi-Dispositivo:** Explorou-se a ideia de treinar cinco classificadores independentes, um dedicado a cada um dos cinco dispositivos. Dependendo da origem da amostra, o sistema utiliza o classificador especializado, permitindo captar melhor as biomecânicas de cada componente corporal.

As melhorias implementadas visam reduzir a confusão observada entre atividades com e sem fala . A remoção de outliers e o balanceamento com SMOTE permitem que o modelo defina melhor os padrões subtis do sinal, resultando numa matriz de confusão mais limpa e num F1-score mais elevado, especialmente na estratégia de divisão por participantes.

17. Conclusão

O trabalho permitiu validar uma pipeline completa de reconhecimento de atividades humanas, desde o pré-processamento físico até à validação estatística rigorosa. A comparação sistemática dos 12 modelos demonstrou que as features manuais superam os embeddings na resolução do problema.